

Глава 1




Рис. 1.1. Три типа машинного обучения




Рис. 1.2. Процесс обучения с учителем




Рис. 1.3. Классификация новой точки данных




Рис. 1.4. Пример линейной регрессии




Рис. 1.5. Процесс обучения с подкреплением




Рис.1.6. Кластеризация




Рис. 1.7. Пример уменьшения размерности с трех измерений до двух




Рис. 1.8. Набор данных Iris




Рис. 1.9. Обобщенная схема процесса прогнозного моделирования

Глава 2




Рис. 2.1. Нейрон, обрабатывающий химические и электрические сигналы




Рис. 2.2. Пороговая функция, определяющая линейную границу решения для задачи бинарной классификации




Рис. 2.3. Примеры линейно разделимых и линейно неразделимых классов




Рис. 2.4. Веса и смещения модели обновляются с помощью функции ошибок

	0	1	2	3	4
145	6.7	3.0	5.2	2.3	Iris-virginica
146	6.3	2.5	5.0	1.9	Iris-virginica
147	6.5	3.0	5.2	2.0	Iris-virginica
148	6.2	3.4	5.4	2.3	Iris-virginica
149	5.9	3.0	5.1	1.8	Iris-virginica

Рис. 2.5. Последние пять строк набора данных Iris




Рис. 2.6. Диаграмма рассеяния цветков setosa и versicolor по длине чашелистиков и лепестков




Рис. 2.7. График зависимости количества ошибок классификации от количества эпох




Рис. 2.8. График областей принятия решения перцептроном




Рис. 2.9. Сравнение перцептрона и алгоритма Adaline




Рис. 2.10. Так работает градиентный спуск




Рис. 2.11. Графики ошибок для неоптимальных скоростей обучения




Рис. 2.12. Сравнение правильно выбранной (слева) и слишком большой скорости обучения (справа)




Рис. 2.13. Сравнение немасштабированных (слева) и стандартизированных (справа) признаков при обновлении градиента




Рис. 2.14. Визуализация областей принятия решений Adaline и среднеквадратичной ошибки (MSE) по количеству эпох




Рис. 2.15. Области принятия решений и график средних потерь после обучения модели Adaline с использованием SGD

Глава 3




Рис. 3.1. Разделяющие границы многоклассовой модели персептрона, обученной на наборе данных Iris




Рис. 3.2. График логистической сигмоидной функции




Рис. 3.3. Логистическая регрессия по сравнению с Adaline




Рис. 3.4. График функции потерь, используемой в логистической регрессии




Рис. 3.5. График области принятия решений для модели логистической регрессии

$$\frac{\partial L}{\partial w_j} = \underbrace{\frac{\partial L}{\partial a} \frac{\partial a}{\partial z} \frac{\partial z}{\partial w_j}}_{\text{Применить цепное правило}}, \quad \text{где } a = \sigma z = \frac{1}{1 + e^{-z}}$$

1. Находим производные по отдельности:

2. Применяем цепное правило и упрощаем:

$$\left. \begin{aligned} \frac{\partial L}{\partial a} &= \frac{a - y}{a \cdot 1 - a} \\ \frac{\partial a}{\partial z} &= \frac{e^{-z}}{(1 + e^{-z})^2} = a \cdot 1 - a \end{aligned} \right\}$$

$$\frac{\partial z}{\partial w_j} = x_j$$

$$\rightarrow \frac{\partial L}{\partial z} = a - y$$

$$\rightarrow \frac{\partial L}{\partial w_j} = \begin{aligned} &a - y \cdot x_j \\ &= -y - a \cdot x_j \end{aligned}$$

Рис. 3.6. Расчет частной производной логарифмической функции правдоподобия




Рис. 3.7. Области принятия решений для модели многоклассовой логистической регрессии scikit-learn




Рис. 3.8. Примеры недообученных, хорошо обученных и переобученных моделей




Рис. 3.9. Влияние параметра обратной регуляризации C на весовые коэффициенты регуляризованной модели L2




Рис. 3.10. Метод SVM основан на поиске наибольшего расстояния между решающей границей и точками обучающих данных




Рис. 3.11. Влияние больших и малых значений обратного коэффициента регуляризации C на классификацию




Рис. 3.12. Области принятия решений SVM




Рис. 3.13. Диаграмма распределения точек данных набора XOR




Рис. 3.14. Процесс нелинейного разделения классов с использованием ядерных методов




Рис. 3.15. Решающая граница для данных XOR, полученная с использованием ядерного метода




Рис. 3.16. Разделяющие границы в наборе данных Iris, полученные с помощью модели SVM (ядро RBF, небольшое значение γ)




Рис. 3.17. Решающие границы в наборе данных Iris, полученные с помощью модели SVM (ядро RBF, значение γ увеличено)




Рис. 3.18. Пример дерева решений




Рис. 3.19. Значения энтропии для различных вероятностей принадлежности к классу




Рис. 3.20. Разделение данных дерева решений




Рис. 3.21. Различные индексы примесей для различных вероятностей принадлежности к классу в интервале от 0 до 1




Рис. 3.22. Решающие границы для данных Iris, полученные с помощью дерева решений




Рис. 3.23. Модель дерева решений, соответствующая набору данных Iris




Рис. 3.24. Области решений для набора данных Iris, полученные с использованием случайного леса




Рис. 3.25. Принцип работы алгоритма k-ближайших соседей




Рис. 3.26. Решающие границы, полученные методом k-ближайших соседей для набора данных Iris

Глава 4

	A	B	C	D
0	1.0	2.0	3.0	4.0
1	5.0	6.0	7.5	8.0
2	10.0	11.0	12.0	6.0

Рис. 4.1. Замена отсутствующих значений в данных средним значением




Рис. 4.2. Использование API scikit-learn для преобразования данных




Рис. 4.3. Использование API scikit-learn для прогностических моделей, таких как классификаторы

	Class label	Alcohol	Malic acid	Ash	Alcalinity of ash	Magnesium	Total phenols	Flavanoids	Nonflavanoid phenols	Proanthocyanins	Color intensity	Hue	OD280/OD315 of diluted wines	Proline
0	1	14.23	1.71	2.43	15.6	127	2.80	3.06	0.28	2.29	5.64	1.04	3.92	1065
1	1	13.20	1.78	2.14	11.2	100	2.65	2.76	0.26	1.28	4.38	1.05	3.40	1050
2	1	13.16	2.36	2.67	18.6	101	2.80	3.24	0.30	2.81	5.68	1.03	3.17	1185
3	1	14.37	1.95	2.50	16.8	113	3.85	3.49	0.24	2.18	7.80	0.86	3.45	1480
4	1	13.24	2.59	2.87	21.0	118	2.80	2.69	0.39	1.82	4.32	1.04	2.93	735

Рис. 4.4. Фрагмент набора данных Wine




Рис. 4.5. Минимизация функции потерь среднеквадратичной ошибки




Рис. 4.6. Применение регуляризации L2 к функции потерь




Рис. 4.7. Применение регуляризации L1 к функции потерь




Рис. 4.8. Влияние гиперпараметра величины регуляризации C




Рис. 4.9. Влияние количества признаков на точность модели




Рис. 4.10. Значимость признаков для модели случайного леса, обученной на наборе данных Wine

Глава 5




Рис. 5.1. Использование PCA для поиска направлений максимальной дисперсии в наборе данных




Рис. 5.2. Доля общей дисперсии, определяемой основными компонентами




Рис. 5.3. Записи из набора данных Wine, спроецированные на двумерное пространство признаков при помощи PCA




Рис. 5.4. Обучающие данные и области принятия решений логистической регрессии после применения класса `PCA` `scikit-learn` для уменьшения размерности




Рис. 5.5. Точки данных тестового набора с областями принятия решений логистической регрессии в пространстве признаков, полученном с помощью PCA




Рис. 5.6. Диаграмма корреляции признаков с первой главной компонентой




Рис. 5.7. Диаграмма корреляции признаков с первой главной компонентой с использованием scikit-learn




Рис. 5.8. Применение LDA к задаче классификации с двумя классами




Рис. 5.9. Два лучших дискриминанта извлекают 100 % полезной информации




Рис. 5.10. Классы Wine идеально линейно разделимы после проецирования данных на первые два дискриминанта




Рис. 5.11. Модель логистической регрессии неправильно определяет класс одного из экземпляров




Рис. 5.12. Модель логистической регрессии отлично работает на тестовых данных






Рис. 5.13. Разница между линейными и нелинейными задачами



Различные виды трехмерного «швейцарского рулета»



«Швейцарский рулет», спроецированный на двумерное пространство признаков с...




Рис. 5.14. Трехмерный «швейцарский рулет», спроецированный вниз в двумерное пространство




Рис. 5.15. Изображения рукописных цифр с низким разрешением




Рис. 5.16. Визуализация того, как t-SNE встраивает рукописные цифры в двухмерное пространство признаков

Глава 6




Рис. 6.1. Внутренние процессы объекта Pipeline (конвейер)




Рис. 6.2. Использование трех разных наборов данных для обучения, проверки и тестирования



Рис. 6.3. Принцип работы k -кратной перекрестной проверки

Рис. 6.4. Общие проблемы моделей




Рис. 6.5. Кривая обучения, показывающая точность на обучающем и проверочном наборах данных в зависимости от количества обучающих примеров




Рис. 6.6. Кривая валидации относительно гиперпараметра C при использовании метода опорных векторов (SVM)




Рис. 6.7. Сравнение поиска по сетке и рандомизированного поиска на примере девяти выборок различных конфигураций гиперпараметров




Рис. 6.8. Иллюстрация идеи вложенной перекрестной проверки




Рис. 6.9. Матрица несоответствий





Рис. 6.10. Матрица несоответствий для наших текущих данных

**Рис. 6.11.** График ROC

Глава 7




Рис. 7.1. Различные принципы голосования




Рис. 7.2. Схема обобщенного ансамблевого подхода




Рис. 7.3. График зависимости между ансамблевой и базовой ошибками




Рис. 7.4. Кривая ROC для различных классификаторов




Рис. 7.5. Границы принятия решений для различных классификаторов




Рис. 7.6. Механизм бэггинга




Рис. 7.7. Пример бэггинга




Рис. 7.8. Форма решающей границы обычного дерева решений по сравнению с бэггингом




Рис. 7.9. Подход AdaBoost к обучению слабых учеников

Индекс	X	y	Вес	$\hat{y}(x \leq 3.0)?$	Верно?	Новые веса
1	1.0	1	0.1	1	Да	0.072
2	2.0	1	0.1	1	Да	0.072
3	3.0	1	0.1	1	Да	0.072
4	4.0	-1	0.1	-1	Да	0.072
5	5.0	-1	0.1	-1	Да	0.072
6	6.0	-1	0.1	-1	Да	0.072
7	7.0	1	0.1	-1	Нет	0.167
8	8.0	1	0.1	-1	Нет	0.167
9	9.0	1	0.1	-1	Нет	0.167
10	10.0	-1	0.1	-1	Да	0.072

Рис. 7.10. Запуск 10 обучающих проходов с помощью алгоритма AdaBoost




Рис. 7.11. Сравнение решающих границ дерева решений и AdaBoost

	Признак x_1	Признак x_2	Метка класса y
1	1.12	1.4	1
2	2.45	2.1	0
3	3.54	1.2	1

Рис. 7.12. Демонстрационный набор данных для иллюстрации применения градиентного бустинга

	Признак x_1	Признак x_2	Метка класса y	Шаг 1: $\hat{y} = \log(\text{odds})$	Шаг 2а: $p = \frac{1}{1 + e^{-\hat{y}}}$	Шаг 2а: $r = y - p$
1	1.12	1.4	1	0.69	0.67	0.33
2	2.45	2.1	0	0.69	0.67	-0.67
3	3.54	1.2	1	0.69	0.67	0.33

Рис.7.13. Результаты первого раунда применения шага 1 и шага 2а





Рис. 7.14. Иллюстрация шагов 2b и 2с, которые подгоняют дерево к остаткам и вычисляют выходные значения для каждого конечного узла

➔

	Признак x_1	Признак x_2	Метка класса y
1	1.12	1.4	1
2	2.45	2.1	0
3	3.54	1.2	1



$F_1(x_1) = 0.69 + 0.1 \times 1.49 = 0.839$

Рис. 7.15. Обновление предыдущей модели, показанное в контексте первого обучающего примера

x_1	x_2	y	Шаг 1: $F_0(x) = \hat{y}$ $= \log(\text{odds})$	Шаг 2a: $p = \frac{1}{1 + e^{-\hat{y}}}$	Шаг 2a: $r = y - p$	Новый log (odds) $\hat{y} = F_1(x)$	Шаг 2a: p	Шаг 2a: r
1	1.12	1.4	0.69	0.67	0.33	0.839	0.698	0.302
2	2.45	2.1	0.69	0.67	-0.67	0.378	0.593	-0.593
3	3.54	1.2	0.69	0.67	0.33	0.839	0.698	0.302

Раунд $m = 1$

Раунд $m = 2$

Рис. 7.16. Значения второго раунда рядом со значениями первого раунда

Глава 8

	review	sentiment
0	In 1974, the teenager Martha Moxley (Maggie Gr...	1
1	OK... so... I really like Kris Kristofferson a...	0
2	***SPOILER*** Do not read this, if you think a...	0

Рис. 8.1. Первые три строки набора данных с обзорами фильмов

Глава 9




Рис. 9.1. Простой пример линейной регрессии с одним признаком




Рис. 9.2. Модель линейной регрессии с двумя признаками

	Overall Qual	Overall Cond	Total Bsmt SF	Central Air	Gr Liv Area	SalePrice
0	6	5	1080.0	Y	1656	215000
1	5	6	882.0	Y	896	105000
2	6	6	1329.0	Y	1329	172000
3	7	5	2110.0	Y	2110	244000
4	5	5	928.0	Y	1629	189900

Рис. 9.3. Первые пять строк набора данных о жилье




Рис. 9.4. Матрица диаграмм рассеяния наших данных




Рис. 9.5. Матрица корреляции выбранных переменных




Рис. 9.6. Функция потерь в зависимости от количества эпох




Рис. 9.7. График линейной регрессии цены продажи недвижимости в зависимости от размера жилой площади




Рис. 9.8. График линейной регрессии с использованием scikit-learn




Рис. 9.9. Инлаеры и аутлаеры, выявленные с помощью модели линейной регрессии RANSAC




Рис. 9.10. Инлаеры и аутлаеры, определенные с помощью модели линейной регрессии RANSAC при увеличенном значении `residual_threshold`




Рис. 9.11. Графики остатков для наших данных




Рис. 9.12. Сравнение линейной и квадратичной моделей




Рис. 9.13. Сравнение различных кривых регрессии, обученных на данных о цене продажи и жилой площади




Рис. 9.14. Линейная, квадратичная и кубическая аппроксимация данных о цене продажи и общем качестве дома




Рис. 9.15. График регрессии на основе дерева решений




Рис. 9.16. Остатки регрессии, полученной по методу случайного леса

Глава 10




Рис. 10.1. Диаграмма рассеяния нашего неразмеченного набора данных




Рис. 10.2. Кластеры, найденные алгоритмом k-средних, и их центроиды




Рис. 10.3. Поиск оптимального количества кластеров с помощью метода локтя




Рис. 10.4. Силуэтный график для примера хорошей кластеризации




Рис. 10.5. Пример неоптимальной кластеризации




Рис. 10.6. Силуэтный график для примера неоптимальной кластеризации




Рис. 10.7. Принцип работы алгоритмов одиночной и полной связи

	X	Y	Z
ID_0	6.964692	2.861393	2.268515
ID_1	5.513148	7.194690	4.231065
ID_2	9.807642	6.848297	4.809319
ID_3	3.921175	3.431780	7.290497
ID_4	4.385722	0.596779	3.980443

Рис. 10.8. Случайно сгенерированная выборка данных

	ID_0	ID_1	ID_2	ID_3	ID_4
ID_0	0.000000	4.973534	5.516653	5.899885	3.835396
ID_1	4.973534	0.000000	4.347073	5.104311	6.698233
ID_2	5.516653	4.347073	0.000000	7.244262	8.316594
ID_3	5.899885	5.104311	7.244262	0.000000	4.382864
ID_4	3.835396	6.698233	8.316594	4.382864	0.000000

Рис. 10.9. Рассчитанные парные расстояния наших данных

	row label 1	row label 2	distance	no. of items in clust.
cluster 1	0.0	4.0	3.835396	2.0
cluster 2	1.0	2.0	4.347073	2.0
cluster 3	3.0	5.0	5.899885	3.0
cluster 4	6.0	7.0	8.316594	5.0

Рис. 10.10. Матрица связей




Рис. 10.11. Дендрограмма наших данных




Рис. 10.12. Тепловая карта и дендрограмма наших данных




Рис. 10.13. Окруженные, шумовые и граничные точки для DBSCAN




Рис. 10.14. Набор данных с двумя признаками и группировкой точек в форме полумесяцев




Рис. 10.15. Кластеризация методом k-средних и агломеративная кластеризация на наборе данных в форме полумесяцев




Рис. 10.16. Кластеризация данных в форме полумесяцев с помощью алгоритма DBSCAN

Глава 11




Рис. 11.1. Алгоритм Adaline




Рис. 11.2. Двухслойный MLP




Рис. 11.3. Сигмоидная функция активации




Рис. 11.4. Примеры написания одной случайно выбранной рукописной цифры из каждого класса




Рис. 11.5. Различные варианты написания рукописной цифры 7




Рис. 11.6. Архитектура нейронной сети для распознавания рукописных цифр




Рис. 11.7. График MSE в зависимости от количества эпох обучения




Рис. 11.8. Точность классификации в зависимости от количества эпох обучения



Рис. 11.9. Рукописные цифры, которые модель не смогла правильно классифицировать




Рис. 11.10. Визуальное представление трехмерного тензора

(Единицы смещения не показаны)






Рис. 11.11. Прямое распространение входных признаков в нейросети



Градиент для веса выходного слоя:

$$\frac{\partial L}{\partial w_{1,1}^{(out)}} = \frac{\partial L}{\partial a_1^{(out)}} \cdot \frac{\partial a_1^{(out)}}{\partial w_{1,1}^{(out)}}$$

Рис. 11.12. Обратное распространение ошибки нейросети



Градиент для веса выходного слоя:

$$\begin{aligned} \frac{\partial L}{\partial w_{1,1}^{(h)}} &= \frac{\partial L}{\partial a_1^{(out)}} \cdot \frac{\partial a_1^{(out)}}{\partial a_1^{(h)}} \cdot \frac{\partial a_1^{(h)}}{\partial w_{1,1}^{(h)}} + \\ &+ \frac{\partial L}{\partial a_2^{(out)}} \cdot \frac{\partial a_2^{(out)}}{\partial a_1^{(h)}} \cdot \frac{\partial a_1^{(h)}}{\partial w_{1,1}^{(h)}} \end{aligned}$$

Рис. 11.13. Вычисление частных производных потерь по первому весу скрытого слоя



Рис. 11.14. Алгоритмы оптимизации могут попасть в ловушку локальных минимумов

Глава 12

Технические характеристики	Intel® Core™ i9-11900KB Processor	NVIDIA GeForce® RTX™ 3080 Ti
Базовая тактовая частота	3,3 ГГц	1,37 ГГц
Количество ядер	16 (32 потока)	10240
Пропускная способность памяти	45,8 Гбит/с	912,1 Гбит/с
Вычисления с плавающей запятой	742 GFLOPS	34,10 TFLOPS
Цена	~\$540,00	~\$1200,00

Рис. 12.1. Сравнение характеристик обычного центрального и графического процессоров




Рис. 12.2. Различные типы тензоров в PyTorch



Рис. 12.3. Изображения кошек и собак




Рис. 12.4. Изображения с метками




Рис. 12.5. Обучающие примеры из набора изображений улыбающихся знаменитостей




Рис. 12.6. Примеры правильно распознанных рукописных цифр




Рис. 12.7. Диаграмма распределения обучающих примеров




Рис. 12.8. Модель линейной регрессии хорошо подогнана к данным




Рис. 12.9. Кривые потерь и точности обучения




Рис. 12.10. Сравнение тангенциальной и логистической функций





Функция активации	Уравнение ^{Танг.}	Пример применения	График
Линейная	$\sigma(z) = z$	Adaline, линейная регрессия	
Ступенчатая (функция Хевисайда)	$\sigma(z) = \begin{cases} 0 & z < 0 \\ 0.5 & z = 0 \\ 1 & z > 0 \end{cases}$	Вариант персептрона	
Знаковая (signum)	$\sigma(z) = \begin{cases} -1 & z < 0 \\ 0 & z = 0 \\ 1 & z > 0 \end{cases}$	Вариант персептрона	
Кусочно-линейная	$(z) = \begin{cases} 0 & z \leq -\frac{1}{2} \\ z + \frac{1}{2} & -\frac{1}{2} \leq z \leq \frac{1}{2} \\ 1 & z \geq \frac{1}{2} \end{cases}$	Метод опорных векторов	
Логистическая (сигмоида)	$\sigma(z) = \frac{1}{1 + e^{-z}}$	Логистическая регрессия, многослойная нейросеть	
Гиперболический тангенс (tanh)	$\sigma(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	Многослойные и рекурсивные нейросети	
ReLU	$\sigma(z) = \begin{cases} 0 & z < 0 \\ z & z > 0 \end{cases}$	Многослойные и сверточные нейросети	

Рис. 12.11. Функции активации, описанные в этой книге

Глава 13

Реализация уравнения $z = 2 \times (a - b) + c$
в виде графа вычислений




Рис. 13.1. Работа графа вычислений




Рис. 13.2. Диаграмма рассеяния обучающих и проверочных примеров





Рис. 13.3. Результаты потерь и точности





Рис. 13.4. Графики потерь и точности после добавления двух скрытых слоев






Рис. 13.5. Результаты обучения модели и диаграмма рассеяния




Рис. 13.6. Результаты обучения модели с использованием `NoisyLinear` в качестве первого скрытого слоя




Рис. 13.7. Структура данных Auto MPG

	MPG	Cylinders	Displacement	Horsepower	Weight	Acceleration	ModelYear	Origin
203	28.0	-0.824303	-0.901020	-0.736562	-0.950031	0.255202	76	3
255	19.4	0.351127	0.413800	-0.340982	0.293190	0.548737	78	1
72	13.0	1.526556	1.144256	0.713897	1.339617	-0.625403	72	1
235	30.5	-0.824303	-0.891280	-1.053025	-1.072585	0.475353	77	1
37	14.0	1.526556	1.563051	1.636916	1.470420	-1.359240	71	1

Рис. 13.8. Предварительно обработанные данные Auto MG




Рис. 13.9. Панель инструментов TensorBoard




Рис. 13.10. Файлы журнала PyTorch Lightning




Рис. 13.11. Панель инструментов TensorBoard после обучения модели в течение пяти дополнительных эпох

Глава 14




Рис. 14.1. Создание карты признаков из изображения (фото Александра Даммера на Unsplash)




Рис. 14.2. Пример заполнения одномерного вектора



Рис. 14.3. Шаги вычисления дискретной свертки




Рис. 14.4. Три режима заполнения




Рис. 14.5. Результат двумерной свертки

$$\begin{array}{|c|c|c|c|c|} \hline 0 & 0 & 0 & 0 & 0 \\ \hline 0 & 2 & 1 & 2 & 0 \\ \hline 0 & 5 & 0 & 1 & 0 \\ \hline 0 & 1 & 7 & 3 & 0 \\ \hline 0 & 0 & 0 & 0 & 0 \\ \hline \end{array}
 \quad
 \begin{array}{|c|c|c|} \hline 0.5 & 0.7 & 0.4 \\ \hline 0.3 & 0.4 & 0.1 \\ \hline 0.5 & 1 & 0.5 \\ \hline \end{array}$$

Рис. 14.6. Вычисление двумерной свертки между входной матрицей и матрицей ядра




Рис. 14.7. Вычисление суммы поэлементного произведения




Рис. 14.8. Пример объединения по максимальному и среднему значению




Рис. 14.9. Реализация CNN




Рис. 14.10. Применение прореживания на этапе обучения

Функции потерь	Варианты классификации	Пример Использование вероятностей	Пример Использование логитов
<i>BCELoss</i> или <i>BCEWithLogitsLoss</i>	Бинарная	<i>BCELoss</i> $y_true:$ 1 $y_pred:$ 0.69	<i>BCEWithLogitsLoss</i> $y_true:$ 1 $y_pred:$ 0.8
<i>NLLoss</i> или <i>CrossEntropyLoss</i>	Много-классовая	<i>NLLoss</i> $y_true:$ 2 $y_pred:$ 0.30 0.15 0.55	<i>CrossEntropyLoss</i> $y_true:$ 2 $y_pred:$ 1.5 0.8 2.1

Рис. 14.11. Два примера функций потерь в PyTorch




Рис. 14.12. Глубокая CNN




Рис. 14.13. Графики потерь и точности при обучении и валидации




Рис. 14.14. Прогнозируемые метки для рукописных цифр




Рис. 14.15. Различные преобразования изображений




Рис. 14.16. Случайные преобразования изображений



Рис. 14.17. Результаты пяти преобразований изображения




Рис. 14.18. Карты входных признаков





Рис. 14.19. Сравнение результатов при обучении и валидации



GT: Улыбка
 $\text{Pr}(\text{Smile})=58\%$



GT: Нет улыбки
 $\text{Pr}(\text{Smile})=4\%$



GT: Нет улыбки
 $\text{Pr}(\text{Smile})=1\%$



GT: Улыбка
 $\text{Pr}(\text{Smile})=98\%$



GT: Нет улыбки
 $\text{Pr}(\text{Smile})=24\%$



GT: Нет улыбки
 $\text{Pr}(\text{Smile})=13\%$



GT: Нет улыбки
 $\text{Pr}(\text{Smile})=15\%$



GT: Улыбка
 $\text{Pr}(\text{Smile})=100\%$



GT: Улыбка
 $\text{Pr}(\text{Smile})=97\%$



GT: Улыбка
 $\text{Pr}(\text{Smile})=93\%$

Рис. 14.20. Метки изображений и вероятности того, что они принадлежат классу 1 (улыбка)

Глава 15




Рис. 15.1. Пример данных временного ряда




Рис. 15.2. Наиболее распространенные типы задач с последовательными данными




Рис. 15.3. Поток данных в стандартной нейросети прямого распространения и в RNN




Рис. 15.4. Примеры RNN с одним (вверху) и двумя (внизу) скрытыми слоями




Рис. 15.5. Применение весов к однослойной RNN




Рис. 15.6. Вычисление активаций




Рис. 15.7. Различные варианты рекуррентных соединений




Рис. 15.8. Проблемы при вычислении градиентов функции потерь




Рис. 15.9. Развернутая структура ячейки LSTM




Рис. 15.10. Схематическое представление того, как работает встраивание




Рис. 15.11. Моделирование языка на уровне символов




Рис. 15.12. Сопоставление символов и целых чисел



Рис. 15.13. Прогнозирование следующего символа текстовой последовательности




Рис. 15.14. Генерация продолжения текста с использованием подхода многоклассовой классификации

Глава 16




Рис. 16.1. Традиционная архитектура кодера-декодера RNN для задачи моделирования «последовательность в последовательность» (seq2seq)

Входное предложение на немецком: Kannst du mir helfen diesen Satz zu uebersetzen ?

Пословный перевод (неправильный): Can you me help this sentence to translate ?

Входное предложение на немецком: Kannst du mir helfen diesen Satz zu uebersetzen ?

Правильный перевод на английский: Can you help me to translate this sentence ?

Рис. 16.2. Пословный перевод предложения может привести к грамматическим ошибкам




Рис. 16.3. RNN с механизмом внимания




Рис. 16.4. Работа базового механизма самовнимания




Рис. 16.5. Вычисление контекстно-зависимого вектора встраивания второго элемента последовательности




Рис. 16.6. Исходная архитектура Transformer




Рис. 16.7. Конкатенация масштабированных векторов внимания в один вектор и его прохождение через линейную проекцию




Рис. 16.8. Расположение слоев в блоке декодера




Рис. 16.9. Сравнение пакетной и послойной нормализации




Рис. 16.10. Два основных способа использования предварительно обученного трансформера для последующих задач





Рис. 16.11. Структура трансформера GPT-1 (подготовлено на основе оригинальной статьи о GPT-1)

Три варианта, рассматриваемые при контекстном обучении


1. Без примеров (Zero-shot)

Модели дается только описание задачи на естественном языке. Обновления веса не выполняются.




2. Один пример (One-shot)

Помимо описания задачи, модели также предоставляют простой пример задачи. Обновления веса не выполняются.



3. Несколько примеров (Few-shot)

Помимо описания задачи, модели также предоставляют несколько простых примеров задачи. Обновления веса не выполняются.



Традиционная тонкая настройка (не для GPT-3)

Тонкая настройка

Модель обучается на большом корпусе примеров задач




Рис. 16.12. Сравнение обучения без примеров, на одном примере и на нескольких примерах




Рис. 16.13. Подготовка ввода для кодировщика BERT



Рис. 16.14. Пример задачи MLM




Рис. 16.15. Тонкая настройка модели BERT под различные языковые задачи




Рис. 16.16. Структура модели BART

	review	sentiment
0	In 1974, the teenager Martha Moxley (Maggie Gr...	1
1	OK... so... I really like Kris Kristofferson a...	0
2	***SPOILER*** Do not read this, if you think a...	0

Рис. 16.17. Первые три строки набора данных обзора фильмов IMDb

Глава 17




Рис. 17.1. Архитектура простейшего автокодировщика




Рис. 17.2. Генеративная модель




Рис. 17.3. Задача дискриминатора — отличить реальное изображение от изображения, созданного генератором




Рис. 17.4. Этапы построения модели GAN




Рис. 17.5. Создание нового блокнота Python в Google Colab




Рис. 17.6. Использование графических процессоров в Google Colab




Рис. 17.7. Подключение вашего Google Drive




Рис. 17.8. Модель GAN с генератором и дискриминатором в виде двух полносвязных сетей




Рис. 17.9. Функция активации ReLU с утечкой




Рис. 17.10. Производительность дискриминатора




Рис. 17.11. Изображения, созданные генератором





Рис. 17.12. Транспонированная свертка

Рис. 17.13. Применение транспонированной свертки к входу 4×4




Рис. 17.14. Процесс пакетной нормализации




Рис. 17.15. Архитектура сети генератора

Сеть дискриминатора




Рис. 17.16. Архитектура сети дискриминатора




Рис. 17.17. Изображения, сгенерированные DCGAN

Показатели	Математическая запись
Полная вариация (Total Variation, TV)	$TV(P, Q) = \sup_x P(x) - Q(x) $
Расхождение Кульбака – Лейблера (KL)	$KL(P Q) = \int P(x) \log \frac{P(x)}{Q(x)} dx$
Расхождение Дженсена – Шеннона (JS)	$JS(P, Q) = \frac{1}{2} \left(KL \left(P \frac{P+Q}{2} \right) + KL \left(Q \frac{P+Q}{2} \right) \right)$
Траншейное расстояние (Earth Mover, EM)	$EM(P, Q) = \inf_{\gamma \in \Pi(P, Q)} E_{(u, v) \in \gamma} (u - v)$





Рис. 17.18. Методы измерения различий между распределениями P и Q

Полная вариация:

$$TV(P, Q) = \sup_x \left\{ \left| \frac{1}{3} - 0.2 \right|, \left| \frac{1}{3} - 0.5 \right|, \left| \frac{1}{3} - 0.3 \right| \right\} = 0.167$$




Расхождение KL:

$$KL(P||Q) = 0.33 \log \left(\frac{0.33}{0.2} \right) + 0.33 \log \left(\frac{0.33}{0.5} \right) + 0.33 \log \left(\frac{0.33}{0.3} \right) = 0.101$$
$$KL(Q||P) = 0.2 \log \left(\frac{0.2}{0.33} \right) + 0.5 \log \left(\frac{0.5}{0.33} \right) + 0.33 \log \left(\frac{0.3}{0.33} \right) = 0.099$$

Расхождение JS:

$$P_m \rightarrow \left[\frac{0.33 + 0.2}{2}, \frac{0.33 + 0.5}{2}, \frac{0.33 + 0.3}{2} \right] = [0.26, 0.42, 0.32]$$
$$\left. \begin{aligned} KL(P||P_m) &= 0.0246 \\ KL(Q||P_m) &= 0.0246 \end{aligned} \right\} \rightarrow JS(P||Q) = 0.0248$$



ЕМ-расстояние:

$$EM(P, Q) = (0.33 - 0.2) + (0.33 - 0.3) = 0.16$$

Рис. 17.19. Пример расчета различных показателей несходства




Рис. 17.20. Изображения, сгенерированные с использованием WGAN




Рис. 17.21. Пример схлопывания моды распределения

Глава 18






Рис. 18.1. Наиболее распространенные типы графов



Граф дружеских отношений



Граф молекулы кофеина

Рис. 18.2. Два примера неориентированных графов






Рис. 18.3. Пример ориентированного графа



Унитарный код
типа атома

Унитарный код
типа связи

SB DB

	C	N	O
1	0	0	0
0	1	0	0
1	0	0	0
0	1	0	0
1	0	0	0
1	0	0	0
1	0	0	0
0	0	1	0
0	1	0	0
1	0	0	0
0	0	1	0
0	1	0	0
1	0	0	0

$$X_E =$$

Матрица
меток
ребер

$A =$
Матрица
смежности


0	1	0	0	0	0	0	0	0	0	0	0	0
1	0	1	0	0	1	0	0	0	0	0	0	0
0	1	0	1	0	0	0	0	0	0	0	0	0
0	0	1	0	1	0	0	0	0	0	0	0	0
0	0	0	1	0	1	0	0	0	0	1	0	0
0	1	0	0	1	0	1	0	0	0	0	0	0
0	0	0	0	0	1	0	1	1	0	0	0	0
0	0	0	0	0	0	1	0	0	0	0	0	0
0	0	0	0	0	0	1	0	0	1	0	0	0
0	0	0	0	0	0	0	0	1	0	1	0	0
0	0	0	0	0	0	0	0	0	1	0	0	0
0	0	0	0	1	0	0	0	1	0	0	1	0
0	0	0	0	0	0	0	0	0	0	1	0	0
0	0	0	0	0	0	0	1	0	0	0	0	0

$$X =$$

Матрица
меток
узлов

(1,2)	1	0
(2,3)	1	0
(2,6)	1	0
(3,4)	0	1
(4,5)	1	0
(5,6)	0	1
(5,12)	1	0
(6,7)	1	0
(7,8)	0	1
(7,9)	1	0
(9,10)	1	0
(9,14)	1	0
(10,11)	0	1
(10,12)	1	0
(12,13)	1	0

Рис. 18.4. Графовое представление молекулы кофеина



Матрица смежности 1:	Матрица смежности 2:	Матрица смежности 3:
$\begin{matrix} \mathbf{D} \\ \mathbf{B} \\ \mathbf{A} \\ \mathbf{C} \end{matrix} \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{bmatrix}$	$\begin{matrix} \mathbf{A} \\ \mathbf{C} \\ \mathbf{D} \\ \mathbf{B} \end{matrix} \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \end{bmatrix}$	$\begin{matrix} \mathbf{A} \\ \mathbf{B} \\ \mathbf{C} \\ \mathbf{D} \end{matrix} \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$

Рис. 18.5. Различные матрицы смежности, представляющие один и тот же граф




Рис. 18.6. Представление графа




Рис. 18.7. Извлечение отношений из графа

Форма сообщения:

$$\sum_{j \in N(i)} M_t(h_i^{(t)}, h_j^{(t)}, e_{ij})$$




Рис. 18.8. Свертки, показанные на графе и в форме сообщения




Рис. 18.9. Устройство и принцип работы простой графовой нейронной сети

Матрицы смежности

$$G_B = \begin{pmatrix} A_1 & 0 & 0 \\ 0 & A_2 & 0 \\ 0 & 0 & A_3 \end{pmatrix},$$

Матрица узлов первого графа

$$\begin{pmatrix} X_1 \\ X_2 \\ X_3 \end{pmatrix}$$

Встраивание признаков первого графа

$$\begin{pmatrix} A_1 & 0 & 0 \\ 0 & A_2 & 0 \\ 0 & 0 & A_3 \end{pmatrix} \times \begin{pmatrix} X_1 \\ X_2 \\ X_3 \end{pmatrix} \times W_1 = \begin{pmatrix} h_1 \\ h_2 \\ h_3 \end{pmatrix}$$

Маска выбора графа

$$\begin{pmatrix} 1 & 1 & \dots & 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & \dots & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 & \dots & 1 & 1 \end{pmatrix} \times \begin{pmatrix} h_1 \\ h_2 \\ h_3 \end{pmatrix} = \begin{pmatrix} \text{orange} & \text{orange} & \text{orange} & \text{orange} & \text{orange} & \text{purple} & \text{purple} \\ \text{purple} & \text{purple} & \text{purple} & \text{purple} & \text{purple} & \text{green} & \text{green} \\ \text{green} & \text{green} & \text{green} & \text{green} & \text{green} & \text{green} & \text{green} \end{pmatrix}$$

Суммарное встраивание признаков первого графа (из глобального объединения)

Рис. 18.10. Работа с графами разного размера




Рис. 18.11. Четыре сгенерированных графа





Рис. 18.12. Прогнозируемая изотропная поляризуемость относительно фактической изотропной поляризуемости

Граф G с кластерами C_1, C_2, C_3, C_4 :



Граф G после
объединения по максимуму:




Рис. 18.13. Применение к графу объединения по максимуму

Глава 19




Рис. 19.1. Взаимодействие между агентом и средой




Рис. 19.2. Использование различных моделей в зависимости от динамики среды




Рис. 19.3. Марковский процесс поведения студента




Рис. 19.4. Пример коэффициента дисконтирования, основанного на изменении ценности 100-долларовой банкноты с течением времени




Рис. 19.5. Различные типы алгоритмов RL




Рис. 19.6. Пример CartPole в Gym

24	25	26	27	28	29
18	19	20	21	22	23
12	13	14	15	16	17
6	7	8	9	10	11
0	1	2	3	4	5

Пространство действий:
{вверх, вниз, влево, вправо}



Вознаграждение:
 $\begin{cases} +1 & \text{если достиг клада} \\ -1 & \text{если попал в ловушку} \\ 0 & \text{в остальных случаях} \end{cases}$

Конечные состояния:

Клад			
16	10	15	22

Начальное состояние:

0

Рис. 19.7. Пример клетчатого мира




Рис. 19.8. Визуализация среды клетчатого мира




Рис. 19.9. Количество ходов агента и его вознаграждения




Рис. 19.10. Пример DQN




Рис. 19.11. Использование глобальной памяти




Рис. 19.12. Определение целевой ценности с помощью DQN




Рис. 19.13. Увеличение вознаграждения агента с течением времени